BEATING THE BASELINE: A COMPARATIVE STUDY OF MODELING TECHNIQUES FOR UK SOCIOECONOMIC TIME SERIES

Diogo A. Freitas[1], João F. Botas[1], Miguel G. Pereira[1], Ricardo A. Galvão[1]

[1]ISCTE – Instituto Universitário de Lisboa, Lisboa, Portugal

Abstract

Este estudo analisa e compara diferentes abordagens de modelação de séries temporais aplicadas a indicadores socioeconómicos do Reino Unido, com ênfase na relação de causalidade com o índice de incerteza política. Foram utilizadas metodologias clássicas, como ARIMA, ETS e Prophet, e técnicas baseadas em redes neuronais/Deep Learning, como RNN, LSTM, GRU, CNN, TCN e modelos híbridos (CNN+LSTM). O objetivo principal foi avaliar a eficácia preditiva de cada modelo em diferentes horizontes temporais, bem como a sua robustez computacional. Os dados analisados incluem anúncios de emprego, rendimentos de obrigações a 10 anos e o índice de incerteza política, cobrindo períodos antes e depois de eventos macroeconómicos relevantes, como o Brexit. A modelação foi implementada com suporte de bibliotecas em Python, destacando o uso das plataformas Darts e TensorFlow. Os resultados revelam que os modelos clássicos superam, em diversos casos, redes neuronais em precisão e eficiência computacional, especialmente em horizontes de curto prazo. Adicionalmente, foi observada uma relação significativa entre a incerteza política e os indicadores económicos através do teste de causalidade de Granger. Este trabalho reforça a importância de uma abordagem equilibrada entre sofisticação algorítmica e viabilidade computacional na modelação de séries temporais socioeconómicas.

Keywords: *time series, socioeconomics, policy, neural networks, modeling, United Kingdom*

1. INTRODUÇÃO

A análise de séries temporais tem vindo a assumir um papel bastante relevante em várias áreas específicas na complexidade inerente aos ramos da economia, saúde pública, ambiente e das ciências sociais, através da modelação e previsão de fenómenos complexos. A sua importância reside na capacidade de capturar padrões temporais, identificar tendências e antever comportamentos futuros com base em dados históricos. No atual contexto de incerteza global e na necessidade das empresas de se reinventarem perante os desafios atuais, a capacidade de antecipar mudanças e agir sobre as mesmas, é mais crucial do que nunca. Assim, ferramentas preditivas baseadas em séries temporais são cada vez mais utilizadas para sustentar decisões políticas, estratégias empresariais, economia, entre as mais diversas áreas que se possa imaginar.

Entre todas as aplicações de séries temporais em contexto real, a previsão de indicadores socioeconómicos - como os anúncios de emprego ou os rendimentos da dívida soberana - revela-se particularmente relevante, tendo sido alvo de diversos estudos e análises nos últimos anos. O Reino Unido constitui um caso de estudo paradigmático para este tipo de análise, pois é caracterizada por uma demografia complexa, uma grande diversidade cultural e certas disparidades regionais, associada a eventos de grande impacto, como o Brexit, que torna o país um terreno interessante para a investigação empírica com dados temporais. A saída do Reino Unido da União Europeia teve implicações negativas na estrutura económica e social do país que, segundo o Banco Central Europeu, provocou uma disrupção significativa nos fluxos comerciais, nos níveis de investimento e na disponibilidade de mão de obra, em especial nas áreas mais dependentes da imigração europeia[1].Outros estudos reforçam este impacto, com alterações substanciais evidenciadas no crescimento económico, nos salários e nas condições de trabalho após o referendo (Tian et al., 2021). Como sintetiza o cientista político Anand Menon, *"The impact has been really quite profound, (…) It's changed our economy (…) And our politics has been changed quite fundamentally as well"*.

Neste sentido, esta combinação de fatores e mudanças profundas no Reino Unido reforçam a pertinência e a motivação para o estudo em questão, que terá um enfoque maior na incerteza política, nos anúncios de emprego e nos rendimentos de obrigações a 10 anos no Reino Unido. Estes indicadores não só representam dimensões fundamentais do comportamento socioeconómico, como são particularmente sensíveis e influenciáveis a eventos exógenos.

[1] https://www.ecb.europa.eu/press/economic-bulletin/articles/2023/html/ecb.ebart202303_01~3af23c5f5a.en.html

O trabalho a realizar propõe-se a explorar várias metodologias de previsão e avaliar a eficácia comparativa de modelos clássicos (como ARIMA e ETS) e modelos baseados em redes neuronais recorrentes (como LSTM e GRU), convolucionais (CNN e TCN) e híbridas (com a mescla de CNN com LSTM). Pretende-se, igualmente, analisar e responder à tese de se estas variáveis/séries influenciam e/ou se correlacionam positivamente com um indicador de incerteza política, ampliando assim a perspetiva preditiva para além dos dados. Com os objetivos principais bem delineados destacam-se também: (i) a comparação de métricas menos exploradas na literatura para a avaliação preditiva sobre diferentes horizontes temporais, (ii) a aplicação de técnicas de otimização de hiperparâmetros, e (iii) a discussão dos limites segundo as abordagens adotadas, bem como a utilização de pacotes do *Python*, específicos para cada efeito.

Em termos de estado da arte, o estudo posiciona-se numa linha de continuidade entre abordagens clássicas consolidadas que exploravam ARIMA e redes neuronais simples em contextos de taxas de câmbio, até a descobertas mais recentes que recorrem a modelos híbridos mais robustos (Zhang, 2003). O foco prende-se, por isso, à avaliação da robustez dos modelos preditivos, tendo em conta diferentes algoritmos e arquiteturas, sempre com consideração ao tempo computacional inerente a estes modelos clássicos e de *Deep Learning*, uma vez que este fator pode representar um entrave significativo à sua aplicabilidade prática e a colmatar numa influência negativa dos resultados. Apesar do avanço na modelação de séries temporais, persistem lacunas na literatura atual. Uma parte considerável dos estudos foca-se em domínios com elevado grau de regularidade e previsibilidade como séries de mercados financeiros, consumo energético ou metereológicas. Ainda assim, muitas estudos que enquadram fatores sociais e económicos concentram-se demasiado na performance preditiva, negligenciando frequentemente questões como o tempo computacional ou comparação de abordagens segundo diferentes pacotes em simultâneo. Estes aspetos são alguns dos quais o estudo se propõe a tratar de forma sistemática.

A estrutura do presente artigo organiza-se da seguinte forma: Secção 2 - demonstra os conceitos e algoritmos implementados, perspectivados num enquadramento teórico necessário; Secção 3 - descreve a metodologia adotada, desde as fases de preparação de dados, passando por testes estatísticos, até aos modelos com as otimizações necessárias; na Secção 4 - discussão dos resultados e enunciadas as limitações quanto às metodologias adotadas de um ponto de vista prático; e, por fim, na Secção 5 - fazem-se elações sobre a *pipeline* adotada e conclui-se o estudo realizado.

2. ENQUADRAMENTO TEÓRICO

O estudo e modelação de time series requer metodologias que tomem especial atenção à natureza sequencial dos dados. Para tal, existem diversos algoritmos, técnicas e métricas adaptadas a este propósito. Nesta secção falar-se-á de: Alisamento Exponencial, ARIMA, Prophet, RNNs, LSTM, GRUs, CNNs, Modelos Híbridos, TCNs e Métricas de correlação e causalidade.

a. Formalização das metodologias
    a. Alisamento Exponencial

Os modelos de alisamento exponencial formam uma família de métodos de previsão frequentemente utilizados para a análise de séries temporais, sendo especialmente valiosos pela sua simplicidade, flexibilidade e eficácia em lidar com diferentes padrões de dados sequenciais. Originalmente propostos por Brown e Holt, estes modelos aplicam pesos exponencialmente menores a observações passadas, dando maior importância a dados mais recentes (Holt, 2004). São então apropriados para a captura de dinâmicas a curto-prazo de séries não estacionárias.

A forma mais básica, Simple Exponential Smoothing (SES), é indicada para dados sem uma perceptível tendência ou padrão sazonal. Para séries mais complexas, esta família de modelos incorpora também uma componente de tendência e uma componente sazonal para modelação de padrões recorrentes no tempo.

Estes modelos são matematicamente recursivos e definidos por poucos parâmetros de alisamento, comummente optimizados por técnicas de minimização de erro. A família dos modelos de alisamento exponencial é precursora de uma representação por espaços de estados como os algoritmos ETS (Erro, Tendência, Sazonalidade) introduzidos por Hyndman et al., que proporcionam tanto uma interpretação probabilística formal, como também seleção de modelos automática.

    b. ARIMA

A família de modelos ARIMA é um esteio da modelação de séries temporais clássica, utilizada frequentemente para modelar séries não estacionárias com tendência ou autocorrelação. Popularizada por Box & Jenkins, estes modelos combinam três componentes: os parâmetros de ARIMA (p, d e q) especificam o grau de cada componente do modelo, um termo autorregressivo de ordem p, que modela a dependência da observação atual com os seus valores do passado;

uma integração de ordem *d*, que indica o número de operações de diferenciação que tornam a série suficientemente estacionária; e uma média móvel de ordem *q*, que utiliza a dependência de erros de previsão passados.

$$ARIMA(p,d,q) = \left(1 - \sum_{i=1}^{p} a_i L^i\right)(1-L)^d y_t = c + \left(1 - \sum_{j=1}^{q} b_j L^j\right)\epsilon_t$$

Esta estrutura de modelos também pode ser estendida para séries temporais com sazonalidade, denominados modelos SARIMA e representados por ARIMA $(p,d,q)(P,D,Q)\cdot S$, que incorporam componentes adicionais sazonais com período S. Estes modelos podem capturar relações de dependência a curto prazo e padrões sazonais de longo prazo.

A estimação tipicamente é feita por máxima verosimilhança ou método de quadrados mínimos (OLS) e validada por verificação de pressupostos dos resíduos, como a visualização da função de autocorrelação. Também é possível a seleção automática do modelo através do uso de critérios de informação, como o BIC ou AIC(c).

c. Facebook Prophet

O Prophet é um modelo *open-source* desenvolvido por Taylor e Letham durante o seu trabalho no Facebook, desenhado para previsão de séries temporais com múltiplas sazonalidades, mudanças de tendência e efeitos de feriados (Taylor & Letham, 2018). O modelo é estruturado:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

Onde, $g(t)$ modela a tendência, $s(t)$ captura a componente de sazonalidade, $h(t)$ os efeitos dos feriados e ϵ_t corresponde ao termo de erro.

As vantagens do Prophet são notórias quanto à sua robustez para dados omissos e *outliers*, como também a sua parametrização intuitiva, permitindo a adição de conhecimento de negócio com facilidade, por exemplo ao especificar pontos de mudança de tendência e dias de feriados. Isto permite que esta arquitetura utilize uma menor rigidez comparada a modelos como ARIMA.

d. *Recurrent Neural Network* (RNNs)

As redes neuronais recorrentes (RNN) são uma arquitetura de redes neuronais artificiais que têm em consideração a ordem dos elementos de entrada, sendo por isso ideal e recomendada para a modelação de séries temporais. Estes modelos diferem das implementações comuns de redes neuronais como os *Multi Layer Perceptron*, pois incorporam laços na sua arquitetura, o que permite a persistência de informação em diferentes passos do tempo. Desta maneira, a rede consegue aprender dependências temporais típicas de dados de séries temporais.

Apesar de as RNNs poderem aprender dependências de longo prazo, frequentemente encontram o problema de *vanishing gradient*[2], o que impede o reconhecimento de padrões de longa duração. Para tentar resolver este problema, foram desenvolvidas variações das RNN, sendo estas: as *Long Short-Term Memory* (LSTM) e *Gated Recurrent Units* (GRU), incorporando mecanismos de "portas" que regulam o fluxo de informação de modo a reterem de forma melhor a informação histórica.

e. *Long Short-Term Memory* (LSTM)

As redes neuronais de memória de curto-longo prazo são uma forma especializada da família das RNN, desenhadas para melhorar os constrangimentos das RNN padrão de modelar dependências temporais de longo-prazo. Esta arquitetura introduz componentes de memória como também mecanismos de "portas" que controlam o fluxo de informação (Taylor & Letham, 2018). Estes mecanismos são os seguintes:

- Uma porta ***forget***, que decide quanta a informação do estado de uma célula deverá ser descartada;
- Uma porta ***input***, que determina quanta a nova informação a considerar;
- Uma porta ***output***, que controla qual a parte da memória que é utilizada para o resultado do modelo.

Estas portas permitem à rede a retenção de informação importante ao longo de duradouras sequências temporais, ao filtrar a informação irrelevante e descartar a desnecessária. Por isso, isto torna as redes LSTM especialmente adequadas a séries com dependências complexas.

f. *Gated Recurrent Units* (GRUs)

[2] https://www.superdatascience.com/blogs/recurrent-neural-networks-rnn-the-vanishing-gradient-problem

As *Gated Recurrent Units* (GRUs) são uma outra variação das RNN. Foram introduzidas por Cho et al. e são conceptualmente semelhantes às LSTM, procurando uma implementação mais simplificada, a redução da complexidade computacional e o treino e convergência mais céleres (Chung et al., 2014).

A arquitetura GRU combina as portas ***input*** e ***forget*** de uma LSTM numa só porta de ***update***, unindo o estado da célula e o estado oculto em uma só memória. Esta redução do número de portas e parâmetros permite um desempenho semelhante às LSTM com uma melhor gestão de memória e a estar menos propensa a *overfitting*.

g. *Convolutional Neural Network* (CNNs)

As CNNs surgiram originalmente para tarefas de visão computacional, mas têm vindo a ser adaptadas com sucesso à análise de séries temporais unidimensionais (Lecun et al., 1998). A sua principal vantagem reside na capacidade de extrair automaticamente padrões locais recorrentes ao longo do tempo, utilizando filtros convolucionais que se deslocam na dimensão temporal. A operação convolucional em séries temporais pode ser definida como:

$$s(t) = (x * w)(t) = \sum_{i=0}^{k-1} x(t+i) \cdot w(i)$$

onde x é a série temporal, w o filtro e k o tamanho do *kernel*. As CNNs permitem uma aprendizagem eficiente e paralelizável, com menor complexidade computacional quando comparadas com redes recorrentes. São particularmente eficazes na extração de padrões locais em séries temporais, como oscilações, picos e transições abruptas, devido à sua capacidade de aplicar filtros convolucionais sucessivamente. No entanto, quando aplicadas com arquiteturas muito profundas ou com um número elevado de parâmetros, o treino pode tornar-se demorado e exigente em termos computacionais. Esta limitação é evidenciada em estudos que mostram que o aumento da quantidade de nós e parâmetros nas redes convolucionais provoca um crescimento significativo no tempo de treino, afetando negativamente o desempenho e a escalabilidade dos modelos (Zebin et al., 2019).

Estudos como o de Wang et al. demonstraram que CNNs aplicadas à classificação de séries temporais conseguem superar métodos tradicionais como o *Dynamic Time Warping* (DTW) e classificadores baseados em árvores (Wang et al., 2016). Para além disso, investigações mais recentes mostram que CNNs também podem ser eficazes na deteção de anomalias em séries temporais multivariadas e dados de redes, pelo que reforça o seu potencial em aplicações reais (Wen & Keyes, 2019).

i. Modelo Híbrido (CNN + LSTM)

Os modelos híbridos que combinam Redes Neuronais Convolucionais (CNN) com Redes Neuronais Recorrentes do tipo Long Short-Term Memory (LSTM) têm-se mostrado muito eficazes na análise de séries temporais, pois juntam as capacidades complementares destas duas arquiteturas. As CNNs são muito boas a extrair automaticamente características locais e padrões espaciais em dados sequenciais, como oscilações, picos ou variações pontuais, através da aplicação de filtros convolucionais que capturam dependências locais. Por outro lado, as redes LSTM são especialmente indicadas para modelar dependências temporais de longo prazo, ultrapassando limitações das redes recorrentes tradicionais, graças à sua capacidade de manter informação relevante ao longo de longas sequências.

A combinação destas técnicas permite que o modelo extraia primeiro as características locais da série temporal usando CNN e, depois, modele a dinâmica temporal dessas características através de LSTM, ao gerar uma representação mais rica e robusta dos dados temporais. Matematicamente, esta arquitetura pode ser expressa da seguinte forma: considerando $X_{input} \in R^{T \times d}$ a série temporal original com T pontos no tempo e dimensão d, as características convolucionais são extraídas por:

$$X_{conv} = f_{CNN}(X_{input}; \theta_{CNN})$$

onde f_{CNN} representa a operação da CNN parametrizada por θ_{CNN}. Posteriormente, essas características convolucionais são usadas como entrada para a camada LSTM, que atualiza o estado oculto h_t em cada instante t pela função:

$$h_t = f_{LSTM}(X_{conv,t}, h_{t-1}; \theta_{LSTM})$$

Onde θ_{LSTM} são os parâmetros da LSTM. Finalmente, a saída do modelo $\hat{y}$, relativa à previsão ou classificação, é obtida através de uma camada final, denotada por:

$$\hat{y} = g(h_T; \theta_{out})$$

com parâmetros θ_{out}.

As vantagens deste modelo híbrido incluem a capacidade de extrair e modelar simultaneamente padrões locais e dependências temporais de curto e longo prazo, resultando em melhorias em tarefas como previsão, classificação e deteção de anomalias, quando comparado com modelos que utilizam apenas CNNs ou apenas LSTM. No entanto, esta combinação pode aumentar a complexidade temporal e computacional, ao exigir cuidados adicionais na escolha dos hiperparâmetros para evitar o *overfitting*. Além disso, a interpretação do modelo torna-se mais desafiadora devido à sua natureza híbrida.

Diversos estudos evidenciam a eficácia desta abordagem. Por exemplo, Mehtab & Sen aplicaram um modelo CNN + LSTM para previsão de séries temporais financeiras, ao destacarem ganhos significativos em relação a modelos isolados de CNN ou LSTM (Mehtab et al., 2020).

ii. Redes Convolucionais Temporais (Temporal Convolutional Networks – TCNs)

As TCNs surgem como uma alternativa às redes recorrentes na modelação de séries temporais, oferecendo vantagens significativas em termos de paralelização, estabilidade do gradiente e capacidade de captar dependências de longo prazo. O principal conceito subjacente às TCNs é o uso de convoluções causais, que asseguram que a saída num instante t não depende de entradas futuras. Além disso, as TCNs utilizam convoluções dilatadas para aumentar o campo receptivo da rede, sem aumentar o número de parâmetros ou profundidade da rede, fazendo com que estas captem padrões de longo alcance na sequência temporal. A operação de convolução dilatada pode ser expressa da seguinte forma:

$$(F *_d k)(t) = \sum_{i=0}^{k-1} F(t - d \cdot i) \cdot k(i)$$

onde F representa a sequência de entrada, K é o kernel convolucional de tamanho, e d é a taxa de dilatação. Esta fórmula evidencia como os elementos da entrada são amostrados através de d, expandindo o alcance da operação de convolução. As TCNs apresentam várias vantagens. Em primeiro lugar, ao contrário das redes recorrentes, permitem paralelização completa do processamento durante o treino, uma vez que as operações convolucionais não são sequenciais.

Em segundo lugar, são mais estáveis em termos de propagação do gradiente e evitam os problemas de *vanishing* ou *exploding* frequentemente observados em redes recorrentes profundas. Finalmente, o uso de arquiteturas com campos receptivos grandes, obtidos através de convoluções dilatadas e múltiplas camadas, confere às TCNs uma elevada capacidade expressiva para tarefas como previsão, deteção de padrões e segmentação em séries temporais.

No entanto, as TCNs não são isentas de limitações. Um dos principais desafios prende-se com a definição do campo receptivo necessário para capturar eficientemente as dependências temporais relevantes. Um campo muito curto pode impedir a aprendizagem de padrões de longo prazo, enquanto campos excessivamente longos podem tornar o modelo computacionalmente ineficiente e difícil de ajustar. Este equilíbrio entre profundidade e desempenho é um aspeto crítico e um fator a ter em conta no *design* de TCNs.

Diversos estudos destacam a eficácia das TCNs Bai et al., num estudo comparativo entre TCNs, RNNs e LSTM, demonstraram que as TCNs superam sistematicamente os modelos recorrentes em tarefas de previsão de sequência, tanto em precisão como em tempo de treino, graças à sua natureza paralelizável (Bai et al., 2018). De igual modo, Lea et al. demonstraram o desempenho superior das TCNs em problemas de segmentação temporal de ações, enquanto He & Zhao aplicaram TCNs à deteção de anomalias em séries temporais industriais, concluindo que esta abordagem alcança resultados mais robustos do que os obtidos com modelos recorrentes tradicionais, graças às vantagens já enunciadas (Lea et al., 2017; He & Zhao, 2019).

h. Métricas de correlação e causalidade

O estudo da causalidade em séries temporais procura identificar relações direcionais entre variáveis, isto é, avaliar se os valores passados de uma variável ajudam a prever os valores futuros de outra. Ao contrário da correlação, que mede apenas associações contemporâneas, as métricas de causalidade incorporam a dimensão temporal e permitem inferir dependências dinâmicas com valor preditivo.

Uma das abordagens mais conhecidas é o teste de causalidade de Granger, que formaliza este conceito de causalidade estatística (Granger, 1969). Esta métrica tem sido amplamente usada em contextos económicos para analisar, por exemplo, se a incerteza política influência variáveis como o PIB, o investimento ou os mercados financeiros.

Trabalhos como o de Baker et al. introduzem o índice de *Economic Policy Uncertainty* e mostram, com recurso a testes de causalidade, os seus efeitos sobre indicadores macroeconómicos (Baker et al., 2016).

i. Correlação de Pearson

A correlação de Pearson é uma medida estatística que avalia a força e a direção da relação linear entre duas variáveis, frequentemente usada como análise inicial entre séries temporais económicas, como a incerteza política e outras variáveis macroeconómicas. O coeficiente r varia entre 1 e -1, indicando correlação positiva, negativa ou ausência de relação linear. A fórmula é dada por:

$$r = \frac{\sum_{t=1}^{T}(x_t - \bar{x})(y_t - \bar{y})}{\sqrt{\sum_{t=1}^{T}(x_t - \bar{x})^2} \cdot \sqrt{\sum_{t=1}^{T}(y_t - \bar{y})^2}}$$

onde x_t e y_t são os valores das séries no instante t, e $\bar{x}$, $\bar{y}$ as respetivas médias. Apesar da sua simplicidade, esta métrica não capta relações não lineares, não infere causalidade e pode ser afetada por *outliers* e autocorrelação, pelo que é vista como um *baseline* para análise exploratória (Shang et al., 2021).

ii. Correlação Cruzada (Pearson com lags)

A correlação cruzada é uma extensão da correlação de Pearson que permite analisar a relação entre duas séries temporais considerando diferentes desfasamentos temporais (*lags*). Esta métrica é útil para identificar se as variações numa série antecedem ou seguem alterações noutra, sugerindo relações temporais de dependência ou influência. Formalmente, a correlação cruzada entre duas séries X_t e Y_t para um lag l é definida como o coeficiente de correlação entre X_t e Y_{t+l}, ou seja,

$$\rho_{XY}(l) = \frac{\sum_t (X_{t+l} - \bar{X})(Y_t - \bar{Y})}{\sqrt{\sum_t (X_{t+l} - \bar{X})^2} \cdot \sqrt{\sum_t (Y_t - \bar{Y})^2}}$$

A análise da correlação cruzada permite detectar atrasos temporais em que a relação entre as séries é mais forte, sendo fundamental para a modelação preditiva e para a inferência de causalidade em séries temporais.

Este procedimento, por vezes designado como “lag Pearson correlation”, tem suporte teórico no estudo de Runge, que explora o uso da correlação de Pearson aplicada a séries temporais com desfasamentos (Runge, 2013).

Apesar da sua utilidade, a correlação cruzada pode ser influenciada por autocorrelações internas nas séries, o que pode conduzir a resultados enviesados se não forem aplicadas técnicas adequadas, como a diferenciação para garantir a estacionariedade dos dados.

iii. Teste de causalidade de Granger

O Teste de Causalidade de Granger é uma metodologia estatística proposta por Granger para avaliar se uma série temporal X_t ajuda a prever outra série temporal Y_t, além da informação contida no próprio passado de Y_t. Em outras palavras, X_t é dita "causar" Granger Y_t se os valores passados de X_t contêm informação útil para prever Y_t. Este teste é geralmente realizado estimando dois modelos autoregressivos:

$$Y_t = \sum_{i=1}^{p} \alpha_i Y_{t-i} + \epsilon_t$$

e

$$Y_t = \sum_{i=1}^{p} \alpha_i Y_{t-i} + \sum_{j=1}^{p} \beta_j X_{t-j} + \epsilon_t$$

onde p é o número de *lags* escolhidos, ϵ_t é o erro branco, e comparam-se os dois modelos para verificar se os coeficientes β_j são estatisticamente significativos. Se o segundo modelo (com os termos de X) melhorar significativamente a previsão de Y, conclui-se que X causa Granger Y. Este método é amplamente utilizado em econometria e análise de séries temporais para identificar relações de causalidade temporal, sendo, contudo, limitado pela suposição de linearidade e pela necessidade das séries serem estacionárias.

3. DADOS E PROCESSOS METODOLÓGICOS

3.1. Dados

Serviram como base deste estudo seis séries temporais da esfera económica e política. Estes dados foram extraídos do FRED (Federal Reserve Economic Data[3]) com recurso à API do próprio portal; para a extração dos valores diários da série da incerteza política, foi acessada a página Economic Policy Uncertainty[4]. Entre as séries apresentadas destacam-se a dos anúncios de empregos e dos rendimentos de obrigações a 10 anos que serão relevantes para as fases de modelação e a do índice de incerteza política para comprovar a nossa tese inicial sobre a causalidade entre as séries. As outras não são mostradas por aparentarem ter uma tendência linear determinística, estando estas presentes no Anexo A.

- **Índice de Incerteza Política do Reino Unido (*Policy Uncertainity*)**: Esta série temporal representa o nível de incerteza em relação à política económica no Reino Unido[5]. A série tem frequência diária entre 1 de janeiro de 2001 e 30 de abril de 2025 (8886 observações).

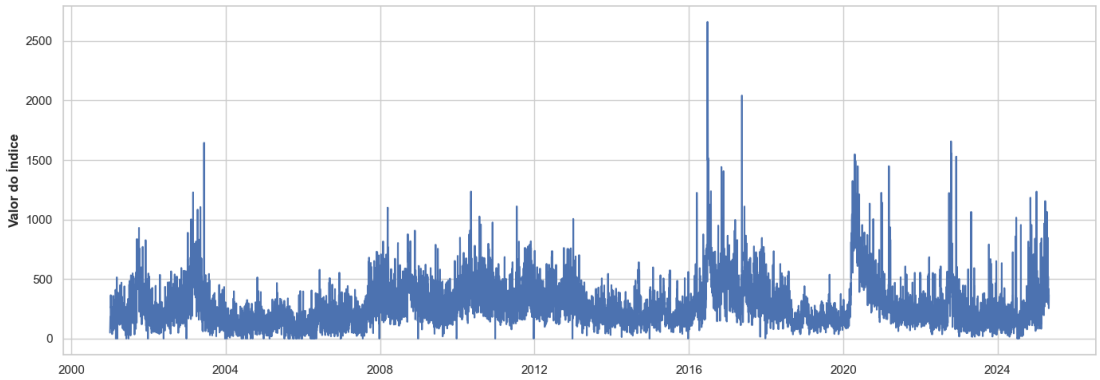


Figura 1- Série Temporal Índice de Incerteza Política do Reino Unido

- **Anúncios de Emprego no Indeed do Reino Unido (*Job Postings*)**: Esta série temporal representa um índice baseado na média móvel de sete dias do número de ofertas de emprego publicadas no site Indeed no Reino Unido, tendo como referência o valor registado no dia 1 de fevereiro de 2020 (base 100). Os valores refletem a evolução relativa em comparação com essa data de referência. A série tem frequência diária, abrangendo o período de 1 de fevereiro de 2020 a 16 de maio de 2025 (1918 observações).

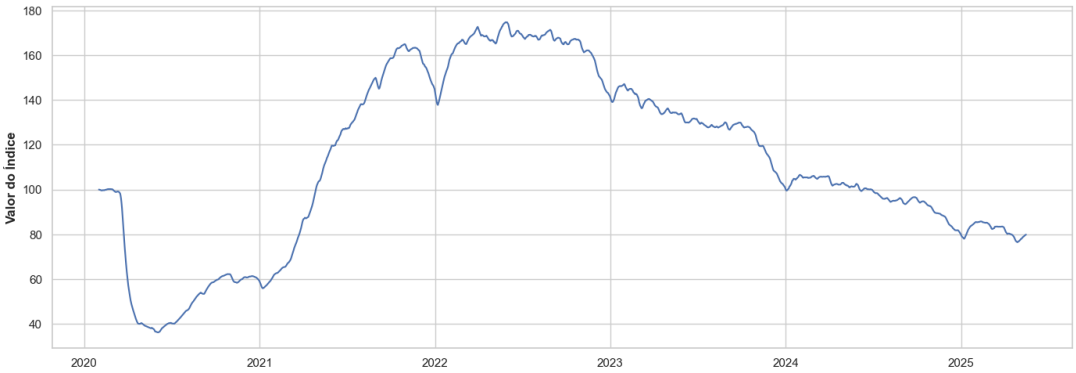


Figura 2 - Série Temporal Anúncios de Emprego no Indeed do Reino Unido

- **Rendimento das obrigações a 10 anos do Reino Unido (*Interest Rates*)**: Esta série temporal representa o valor percentual que os investidores exigem como retorno ao adquirirem títulos de dívida pública britânica com maturidade de 10 anos. A série tem frequência mensal entre janeiro de 1960 e de abril 2025 (783 observações).

[3] Dados disponíveis na seguinte ligação: https://fred.stlouisfed.org/
[4] Para o acesso aos dados diários: https://www.policyuncertainty.com/uk_monthly.html
[5] Os cálculos podem ser observados em maior detalhe em: https://www.policyuncertainty.com/media/BakerBloomDavis.pdf



Figura 3 - Série Temporal Rendimento das obrigações a 10 anos do Reino Unido

- **Índice de Preços ao Consumidor para o Reino Unido**: Esta série temporal representa o cálculo do IPC segundo os métodos padronizados (COICOP 1999 e IHPC) no Reino Unido. Os seus valores correspondem a um índice com base 100 no ano de 2015, refletindo a evolução relativa dos preços ao consumidor em relação a esse ano. A série tem frequência mensal entre janeiro de 1955 e março de 2025 (842 observações).

- **Preços da Propriedade Residencial do Reino Unido**: Esta série temporal representa a evolução do valor médio dos imóveis residenciais no Reino Unido, com base 100 em 2010. A série tem frequência trimestral entre janeiro de 1955 e outubro de 2014 (226 observações).

- **Produto Interno Bruto do Reino Unido**: Esta série temporal representa o valor do Produto Interno Bruto (PIB) do Reino Unido, ajustado sazonalmente e expresso em preços correntes. A série tem frequência trimestral entre janeiro de 1955 e março de 2025 (227 observações).

3.2. Procedimentos Metodológicos

Para a elaboração dos modelos e de todos os processos antecedentes a estes foi utilizado o Python com *libraries* distintas para cada etapa. Numa fase inicial de Análise Exploratória de Dados destaca-se a utilização de bibliotecas focalizadas em gráficos (*matplotlib* e *seaborn*), *statsmodels* e *scipy* para a utilização de testes estatísticos e decomposições das séries temporais, bem como a do *fredapi*, que foi fundamental em todas as fases seguintes para retirarmos as séries mais facilmente do próprio portal do FRED. Já nas fases de modelação e previsão, para além de algumas *libraries* já mencionadas, seguiram-se dois caminhos distintos: utilização de *Darts* para modelos clássicos e redes neuronais recorrentes (RNN); *Darts* e *Tensorflow* para a execução de modelos híbridos e comparação de performance entre os dois pacotes; e *statsmodels* para o Granger, a fim de identificar alguma causalidade entre as séries de fatores socioeconómicos e a incerteza política no UK.

Na Análise Exploratória de Dados pretende-se analisar e extrair informações quanto a vários aspetos das séries estudadas, mencionadas na Secção 3. Começou-se por extrair informações quanto às características e dispersão da série. Para caracterizar a distribuição e variações das séries temporais, foram inicialmente construídos *boxplots* segmentados por ano ou por mês, conforme a frequência de cada série, de modo a observar padrões de dispersão, presença de *outliers* e eventuais alterações e flutuações sazonais ao longo das séries. Prosseguiu-se com a decomposição das séries nas suas componentes fundamentais - tendência, sazonalidade e ruído -através de métodos aditivos e multiplicativos, consoante a natureza da variação sazonal, bem como a análise das forças de tendência e sazonalidade. Esta decomposição foi ainda complementada com uma função do *Darts*[6], para verificar a sazonalidade a partir de um máximo de *lags*, e com uma análise gráfica das funções de autocorrelação (ACF) e autocorrelação parcial (PACF), para identificar padrões de dependência temporal e sazonalidade residual nas séries através dos "picos" recorrentes nos gráficos.

Realizaram-se ainda testes estatísticos para comprovar e validar, com rigor analítico, as nossas crenças e evidências preliminares observadas nas séries. Os resultados são interpretados com base nas estatísticas de teste e *p-values*. A avaliação da estacionaridade das séries foi feita através dos testes do KPSS (Kwiatkowski–Phillips–Schmidt–Shin) e ADF (Augmented Dickey-Fuller); o primeiro testa a hipótese nula de estacionaridade, enquanto o segundo testa a hipótese nula de presença de raiz unitária (não estacionaridade). No que diz respeito à normalidade das séries, recorreu-se aos testes da curtose e assimetria e a análise dos seus coeficientes, bem como ao teste de Jarque-Bera como proposta de desempate destes dois últimos, de forma a aferir desvios em relação à distribuição normal.

[6] check_seasonality() do *Darts* para retornar se a série é sazonal ou não e com que frequências

Adicionalmente, o teste de Lagrange Multiplier foi utilizado para verificar a presença de autocorrelação nos resíduos, enquanto o teste BDS (Brock–Dechert–Scheinkman) foi aplicado para detetar não linearidades e dependências complexas. Foi igualmente conduzida uma análise de quebras de estrutura, através do algoritmo de CUSUM, com o objetivo de identificar mudanças abruptas no comportamento das séries ao longo do tempo e a reportar alarmes de quebras por um valor de *threshold*.

Ainda, para cada série, foram efetuadas análises complementares específicas, consoante as suas características intrínsecas. Estas incluíram, entre outras, a análise da variabilidade intra-anual, visualizações mais detalhadas de sazonalidade e colocações de hipóteses com situações e acontecimentos do mundo real.

Na fase de modelação e previsão foram realizadas uma sequência de etapas que se separou idealmente em: (1) modelos clássicos; (2) modelos de redes neuronais recorrentes como LSTM, GRU; (3) modelos de redes neuronais convolucionais e híbridos; (4) e finalmente modelos de relação-causalidade com Granger.

Para os modelos clássicos e modelos da família das RNN foram utilizados os métodos abordados na Secção 2 e considerou-se a preferência pelo *darts*, em detrimento do *Tensorflow*. Esta decisão foi motivada, sobretudo, pela maior simplicidade na operação dos algoritmos com suporte à GPU, uma vez que o *darts* opera com *backend* em *PyTorch*, sendo particularmente vantajosa dado o custo computacional potencialmente elevado à modelação nestes algoritmos. Adicionalmente, a disposição a funcionalidades integradas tanto para modelos clássicos – como autoARIMA, autoETS e Prophet - quanto para modelos baseados em RNN - como RNN, LSTM e GRU – na mesma biblioteca, acompanhou e facilitou todo o processo de desenvolvimento e experimentação. Esta escolha é ainda mais suportada por recomendações literárias, que destacam estas vantagens já enunciadas, mas também outras como a representação das séries temporais num único "*container*"/objeto, algo que facilita a manipulação destas ao longo do *pipeline* (Herzen et al., 2021).

É importante salientar que, na modelação de séries temporais, a conformidade com certos pressupostos deve ser cuidadosamente considerada, tendo como referência as inferências da Análise Exploratória de Dados. No caso dos modelos clássicos, nomeadamente ETS, ARIMA e Prophet, não foi necessário impor condições explícitas de estacionaridade. No modelo ARIMA é incorporado o tal parâmetro de diferenciação que permite lidar com séries não estacionárias como *input* do modelo, enquanto nos modelos de ETS e Prophet não é assumido, nem requerido, a estacionaridade como pré-condição, pois são concebidos para modelar diretamente tendência e sazonalidade. Já para os modelos de redes neuronais foi necessário aplicar-se normalização dos dados para melhorar a estabilidade numérica e acelerar a convergência durante o treino. Para tal procedeu-se ao *scaling* pela divisão do valor y_t pelo máximo absoluto, de forma a garantir que os dados se encontrassem no intervalo [-1, 1].

No âmbito da análise com Redes Neuronais Convolucionais (CNN), foram estabelecidos três objetivos principais: (3.1.) Comparar a performance e a complexidade computacional entre os frameworks *TensorFlow* e *PyTorch*, avaliando não apenas a velocidade de treino e inferência, mas também a facilidade de implementação e compatibilidade com GPU (Novac et al., 2022); (3.2.) Estudar a evolução do desempenho entre modelos CNN puros e modelos híbridos, nomeadamente a combinação CNN + LSTM, de forma a compreender o impacto da componente temporal na qualidade das previsões; (3.3.) Avaliar o comportamento das Temporal Convolutional Networks (TCN), disponíveis na biblioteca *Darts*, comparando os seus resultados com os modelos híbridos anteriormente testados (Gopali et al., 2021);

Para o *framework TensorFlow*, foi necessário criar um ambiente isolado através de um container Docker, uma vez que a versão estável do *TensorFlow* não suporta, por omissão, as versões mais recentes do CUDA. Esta limitação inviabilizaria o uso da GPU no treino das redes neuronais. O problema foi, contudo, ultrapassado com sucesso, tendo sido possível configurar o ambiente corretamente. A documentação e os ficheiros relevantes encontram-se disponíveis no repositório público de apoio[7]. Tanto para os modelos CNN como para os híbridos (CNN + LSTM), foi seguido um protocolo rigoroso de consistência: foram utilizados os mesmos procedimentos de pré-processamento, estrutura de neurónios, parâmetros, hiperparâmetros e *callbacks*, com o objetivo de garantir uma comparação justa e fidedigna entre os diferentes modelos.

Para a análise da relação causal entre séries temporais (4), utilizou-se como variável explicativa principal a incerteza política no Reino Unido, com o objetivo de avaliar o seu impacto nas restantes séries — como as ofertas de emprego, os preços das habitações, entre outras.

Para garantir a comparabilidade entre as séries, procedeu-se inicialmente à uniformização das frequências temporais, ajustando a periodicidade da variável base às restantes. Posteriormente, foram aplicadas diversas abordagens para

[7] Documento de suporte: https://github.com/GothamAnalytics-7/ASTP

aferir a existência de causalidade, desde correlações simples, desfasamentos temporais (*lags*), ao teste de causalidade de *Granger*.

Esta combinação metodológica permitiu captar não apenas relações contemporâneas, mas também efeitos dinâmicos e diferidos da incerteza política sobre variáveis macroeconómicas chave.

3.2.1. Treino e validação dos modelos

O processo de treino e validação dos modelos seguiu uma estrutura diferente consoante a natureza dos algoritmos utilizados. Para os modelos clássicos, foi adotada uma estratégia de *hold-out*, dividindo-se a série temporal original em duas partes: 90% foi utilizada para treino, enquanto os 10% restantes para validação. Nas visualizações utilizou-se uma fração de 70% da série para facilitar a interpretação dos resultados apenas.

A avaliação destes modelos foi realizada com uma abordagem de *backtesting* com validação deslizante (*walk-forward validation*), com vários valores de horizontes que acabam por simbolizar a unidade de frequência da série. Para o valor do horizonte designemos de $x \in \{1,2,3,5,7,15,30\}$. Esta técnica vai simular e fazer previsões sucessivamente com reavaliação do treino do modelo repetidamente. No caso dos modelos baseados em redes neuronais foi adotada a mesma proposta de *backtesting*, mas com uma divisão de 80/10/10 para treino, validação e teste, respetivamente. A ideia por trás de ter um conjunto de validação é para controlar o *overfitting* e comparar as curvas de *loss* ao longo das fases de treino. O treino e validação destes modelos foram executados com hiperparâmetros *default*, numa primeira fase, e otimizados com *Optuna* posteriormente.

No caso das CNN, a divisão entre treino e validação apresentou algumas diferenças subtis. Inicialmente, foram adotadas duas abordagens distintas: *Fixed Window* e *Sliding Window Cross Validation* (10 folds). Na abordagem Fixed Window, a divisão dos dados seguiu a proporção clássica de 80% para treino, 10% para validação e 10% para teste. Por outro lado, na abordagem Sliding Window, a divisão foi ajustada para 70% treino, 20% validação e 10% teste, uma vez que a segmentação da série temporal em 10 folds visava não só avaliar a robustez do modelo ao longo do tempo, mas também permitir uma melhor visualização das previsões em diferentes janelas temporais, facilitando a interpretação e comparação dos resultados gerados pelo modelo.Esta escolha visou simplificar a divisão, evitando que os conjuntos de validação e teste ficassem demasiado reduzidos, o que comprometeria a fiabilidade da avaliação do modelo.

3.2.2. Métricas de avaliação

Como métricas de avaliação começou-se por considerar o MAPE que utiliza a diferença do valor real e previsto, em termos absolutos. Esta métrica garante que os erros estão na mesma escala da original e não é tão ambíguo como o RMSE (Willmott & Matsuura, 2005). Para além do mais, tem a vantagem de ser adimensional, onde é expressa em valores percentuais ("Absolute Percentual Error"), contrariamente ao MAE ("Absolute Error"), algo que torna a sua interpretação mais fácil.

$$MAPE = \frac{\sum_{i=1}^{s} \left| \frac{y_{t+1} - \hat{y}_{t+1}}{y_{t+1}} \right|}{s} \times 100$$

Apesar do MAPE beneficiar destes aspetos, este não pode ser utilizado para valores nulos e, por isso, surge na literatura a utilização do sMAPE que é uma medida que redefine o denominador da fórmula do MAPE para o valor médio entre a previsão e o valor real. Isto permite que a métrica tenha mais resistência e sensibilidade a *outliers* e evita que os erros explodam para valores muito elevados, ou até infinitos (Chen et al., 2017). Ainda assim, o sMAPE foi muito criticado, na M3-Competition, onde diversos investigadores apresentaram dificuldades na interpretação desta métrica, sendo inclusive referida no artigo como "*poor interpretability*". A sua ambiguidade reside, sobretudo, com os limites da métrica que podem ter duas formas: variar entre 0-100% ou 0-200%, sendo a segunda, a incluída na biblioteca do *Darts* por omissão (Ramesh & Usman, sem data). No intervalo de 0-200% é referido[8] que esta pode ser analisada de forma semelhante ao MAPE para erros percentuais compreendidos entre -30% e +30%, onde a diferença entre ambas as métricas é marginal. No fim de contas, esta métrica considerou-se, com a ressalva que deve ser interpretada de maneira cuidadosa e levando em conta a literatura encontrada.

[8] De acordo com a seguinte fonte do Medium: https://medium.com/@davide.sarra/how-to-interpret-smape-just-like-mape-bf799ba03bdc

$$sMAPE = \frac{1}{s}\sum_{i=1}^{s}\frac{|y_{t+1} - \hat{y}_{t+1}|}{(|y_{t+1}| + |\hat{y}_{t+1}|)/2} \times 100$$

Também se utilizou o coeficiente de determinação (R^2) com o intuito de avaliar a proporção da variabilidade da série temporal que é explicada pelo modelo. Ou seja, serve para medir o quão bem as previsões seguem a tendência dos dados observados ao longo do tempo.

$$R^2 = 1 - \frac{\sum_{i=1}^{s}(y_{t+1} - \hat{y}_{t+1})^2}{\sum_{i=1}^{s}(y_{t+1} - \bar{y}_{t+1})^2}$$

Então, foram utilizadas estas três métricas de erro para avaliar comparativamente o desempenho dos diferentes tipos de modelos em cada uma das séries.

Ademais, no contexto dos modelos clássicos, e mais especificamente na modelação com ARIMA, foi possível recorrer à seleção automática das especificações do modelo com base em critérios de informação. Mesmo estando mais enquadrada na escolha dos melhores hiperparâmetros, acaba por ser uma métrica que vai avalia os modelos e, por isso, será abordada nesta secção, reconhecendo que a sua natureza principal é a de uma técnica de otimização, no contexto da função.

Para o efeito, e como já foi referido, utilizou-se o autoARIMA do *Darts* que permite especificar um critério desejado diretamente na escolha dos hiperparâmetros (p,d,q). No nosso estudo foram considerados os critérios do AIC (Akaike Information Criteria) e BIC (Bayesian Information Criteria). Ambos os critérios têm como objetivo encontrar um equilíbrio entre a qualidade do ajuste do modelo e a sua complexidade, penalizando os modelos com maior número de parâmetros para evitar *overfitting*. Contudo, o BIC, comparativamente ao AIC, impõe uma penalização mais severa à complexidade do modelo, pois advém da minimização de um modelo de regressão com vários *lags* como base, bem como da inclusão do tamanho da amostra (N) como fator de penalização, algo que o torna mais conservador conforme o número de observações aumenta.

$$AIC = -2 \cdot \log(\hat{L}) + 2 \cdot k$$

$$BIC = -2 \cdot \log(\hat{L}) + k \cdot \log(n)$$

Optou-se por utilizar complementarmente o AICc (Corrected Akaike Information Criteria), que, tal como o nome sugere, é uma correção do AIC, mas ajustada para amostras pequenas, de forma a produzir estimativas mais fiáveis em contextos com dados de elevada variabilidade. Desta forma, permite adaptar a fórmula de cálculo do AIC para casos em que o número de parâmetros é muito próximo ao número de parâmetros estimados, de forma a evitar *overfitting*.

$$AICc = AIC + \frac{2 \cdot k^2 + 2 \cdot k}{n - k - 1}$$

A inclusão destes critérios permitiu comparar, de forma empírica, como a escolha do critério influencia a performance preditiva dos modelos, especialmente em cenários como o descrito simulados por *backtesting*.

Ainda, como forma adicional de avaliar o desempenho dos modelos, para além dos valores das métricas de erro mencionados, foi utilizado um modelo de referência simples, apelidado de *baseline*, que possuía o valor das métricas intrínsecas. Este modelo "*lazy*" baseava-se na previsão direta do valor observado em y_{t-x}, ou seja, em que $y_{t+x} = y_t$, onde x corresponde ao horizonte definido - mencionado na Secção 3.2.1 - de acordo com a frequência da série (por exemplo, dias no caso da série de anúncios de emprego). A simplicidade deste modelo acaba por torná-lo útil como comparação mínima, em que qualquer modelo preditivo só é considerado eficaz se conseguir superar sistematicamente este *baseline* nas métricas utilizadas.

3.2.3. Ajuste de hiperpârametros

Foi empregue o *Optuna* para a otimização dos hiperparâmetros dos modelos. Este pacote revelou-se eficaz nos modelos de redes neuronais recorrentes, no sentido em que permitiu encontrar configurações que melhorassem os resultados preditivos dos modelos, como também garantir a automatização e flexibilidade das várias experiências, num ambiente sistemático e reprodutível. A abordagem adotada consistiu na definição dos espaços de procura para os principais hiperparâmetros, como o número de camadas das redes, unidades por camada, taxa de *dropout*, tamanho dos *batches* e da janela deslizante e valores da taxa de aprendizagem do otimizador *Adam*.

No entanto, embora tenha sido considerada e até implementado o *Optuna* para os modelos ETS e ARIMA, de forma a comparar a implementação das formas "auto" das funções do *Darts*, esta acabou por não ser aprofundada porque preferiu-se a abordagem mais conservadora, dado que o tempo computacional é algo que se deve sempre prezar como uma consideração. Para os modelos clássicos, bem como para os modelos de CNN bases, o modelo híbrido de CNN+LSTM e TCN, não foi adotada esta estratégia devido à elevada quantidade de hiperparâmetros e, consequentemente, à alta complexidade temporal que impedia a conclusão do processo com uma maior efetividade e com resultados mais consistentes que as funções pré-definidas. No caso das CNN (3), foram escolhidos os parâmetros manualmente, enquanto nos modelos clássicos foi sugerida a abordagem já descrita, baseada nos critérios de informação com a forma automática do *Darts*.

3.2.4. Limitações, Considerações e Desafios

Apesar do rigor metodológico explicitado, alguns desafios e limitações devem ser reconhecidos neste estudo.

Em primeiro lugar, o custo computacional revelou-se, em todo o processo, um fator primordial nas fases de modelação e otimização de hiperparâmetros. Modelos como redes neuronais recorrentes (LSTM, GRU) ou com convoluções requerem um tempo de treino acentuado, particularmente quando aplicados em séries temporais com horizontes de previsão alargados para o *backtest*. Para isso, como já foi dito, escolhas de ferramentas como o *Darts*, com *backend* em *PyTorch*, permitiram mitigar, de certa maneira, algumas destas dificuldades, pela compatibilidade com GPUs e simplicidade de implementação face a alternativas como o *TensorFlow*, onde vê-se a necessidade de implementar ambientes complexos com o Docker.

No que diz respeito aos dados, não foram detetados problemas de *missing values* nas séries analisadas, o que simplificou o pré-processamento. Contudo, é importante destacar que as séries em estudo apresentavam frequências distintas, o que resultava num número variável de observações. Para manter a análise mais coesa e interpretável, optou-se por focar os resultados da modelação nas séries das Vagas de Emprego e dos Rendimentos das Obrigações a 10 anos, visto que oferecem um equilíbrio entre volume de dados e relevância económica, para além de serem mais imprevisíveis de prever, o que torna a modelação mais interessante. Apesar desta decisão, a rotina computacional desenvolvida mostrou-se ser ajustável para ser aplicada a qualquer outra série que fosse considerada, dentro ou fora do escopo inicial do estudo.

Por último, e por se tratar de dados de natureza social e económica, existe sempre o risco de viéses exógenos ou fatores latentes que não são capturados diretamente nas séries. A possibilidade de eventos imprevistos, como choques macroeconómicos, mudanças de política pública (por exemplo o Brexit, cujos efeitos afetaram indicadores sociais e económicos no Reino Unido), ou alterações comportamentais podem introduzir variabilidade nos dados, que, nem toda a complexidade subjacente aos modelos de *Deep Learning* consegue captar, modelar e prever.

4. RESULTADOS

4.1. Análise das Séries Temporais

Nesta análise serão abordadas as séries temporais Job Postings e Interest Rates - respetivamente Fig.2 e Fig.3 da Secção 3.1.

Pela observação da Fig.2 é observada uma tendência não linear, com variações estruturais significativas. O período observável começa no dia do *Brexit* onde existe estabilidade da oferta, uma queda abrupta nos primeiros meses de 2020 associada ao impacto da pandemia de COVID-19 e medidas de isolamento social, que reduziu a oferta de emprego de curta duração.

Iniciada nos últimos meses de 2020 e com intensificação em 2021, deu-se uma retomada das contratações para níveis não observados anteriormente, dado que neste período existiu uma recuperação da economia e uma oferta nunca vista de teletrabalho. Depois de atingido o pico no ano de 2022, a tendência verificada é decrescente até à atualidade com uma aparente estabilização nos últimos meses observados, dado que neste período, a economia global apresenta declínio. Na decomposição da série é possível observar também a sazonalidade anual da série.

Na observação da Fig.3 é também notória a tendência não linear, para o período inicial é evidenciada uma forte tendência de crescimento dos valores oferidos até à década de 1980, dado que no seguinte período são adotadas políticas monetárias mais restritivas e de contenção da inflação.

No contexto recente, especialmente a partir de 2020, a pandemia da COVID-19 provocou perturbações nos mercados financeiros e levou os rendimentos das obrigações a níveis historicamente baixos, devido à implementação de

políticas expansionistas por parte dos bancos centrais. Este fenómeno foi visível ao longo de 2020 e 2021, quando os rendimentos se mantiveram em níveis extremamente reduzidos.

A partir de 2022, observa-se uma nova mudança na dinâmica da série: os rendimentos começaram a subir significativamente, impulsionados pelo aumento da inflação e pelas sucessivas subidas das taxas diretoras por parte do Banco de Inglaterra. Desde então, os valores estabilizaram num patamar mais elevado, quando comparado com o período anterior à pandemia. Esta série não apresenta sazonalidade.

Os testes de normalidade, estacionaridade e independência foram rejeitados para qualquer nível de significância nas duas séries temporais em análise. De facto, os resultados obtidos fornecem evidência estatística para as seguintes conclusões:

Os testes aplicados (Kurtosis, Skewness, Jarque-Bera e Kolmogorov–Smirnov) levam à rejeição da hipótese nula de normalidade em praticamente todos os casos. Assim, não se rejeita a hipótese alternativa de que os dados não seguem uma distribuição normal, o que é confirmado pelas estatísticas extremas observadas, sobretudo na série *Job Postings*.

Através do teste de Dickey-Fuller aumentado (ADF), observa-se que a hipótese nula de presença de raiz unitária (indicadora de não estacionaridade) não é rejeitada em ambas as séries. Simultaneamente, o teste KPSS apresenta estatísticas superiores aos valores críticos de referência, conduzindo à rejeição da hipótese nula de estacionaridade. Em conjunto, estes resultados reforçam a evidência de que ambas as séries são não estacionárias.

Violação da independência e da hipótese de dados i.i.d. (independentes e identicamente distribuídos): Os testes de independência (teste de Lagrange e teste BDS) rejeitam, com elevada significância estatística, a hipótese nula de que os dados são i.i.d. Isto sugere a existência de estrutura de dependência serial e comportamento não linear nas séries temporais, indicando que os dados não são independentes nem apresentam variabilidade constante ao longo do tempo.

Tabela 1- Testes de Normalidade, Estacionaridade e Independência - Séries Anúncios de Emprego no Indeed e Rendimentos de Obrigações

		Testes de Normalidade				**Testes de Raiz Unitária/ Estacionaridade**		**Teste de Independência**	
		Kurtosis	Skewness	Jarque-Bera	Kolmogorov-Smirnov	ADF	KPSS	Multiplicador de Lagrange	BDS (Dim.2-Dim.6)
Job Postinas	***statistic***	-25.1498	-2.6897	1014.6346	1.0000	-1.5200	1.6362	1921.9677	229.6260 - 388.2697
	p-value	0.0000*	0.0072*	0.0000*	0.0000*	0.5236**	---------	0.0000*	0.0000*
Rendimento Obriaacões	***statistic***	-7.3373	3.3131	30.4314	0.8596	-1.3012	2.6030	764.7514	113.8139-171.7680
	p-value	0.0000*	0.0009*	0.0000*	0.0000*	0.6286**	---------	0.0000*	0.0000*

*Rejeita-se *H*0 para os níveis de significância de 1%, 5% e 10%

**Não se Rejeita *H*0 para os níveis de significância de 1%, 5% e 10%

Os resultados da modelação das séries temporais estudadas encontram-se na seguinte secção.

4.2. Anúncios de emprego no Indeed

4.2.1. Modelos clássicos

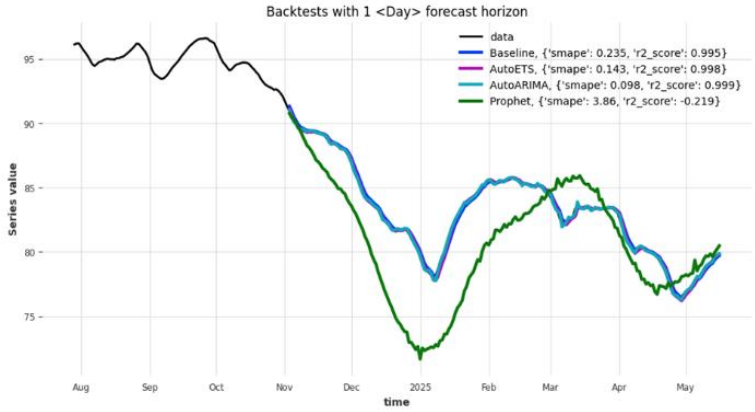


Figura *4* – Gráfico de resultados de validação deslizante dos modelos clássicos para a série anúncios de emprego no Indeed para o horizonte de um dia

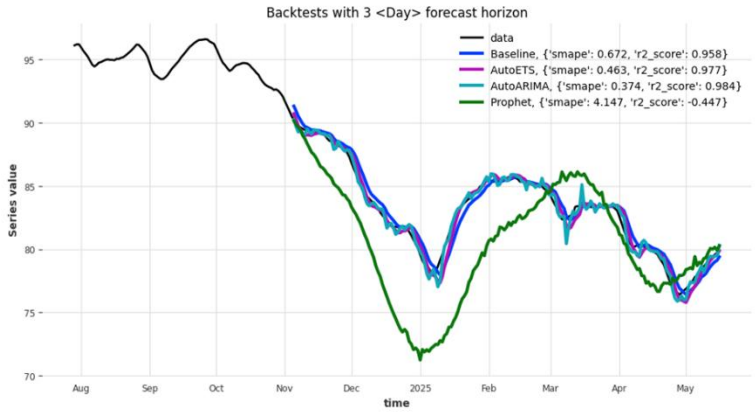


Figura *5* – Gráfico de resultados de validação deslizante dos modelos clássicos para a série anúncios de emprego no Indeed para o horizonte de três dias

Realizada a modelação da série temporal de Anúncios de Emprego no Indeed, os resultados da validação deslizante para os modelos clássicos foram:

Tabela 2– Resultados de validação deslizante da série anúncios de emprego no Indeed para os modelos clássicos

	Baseline		**AutoETS**		**AutoARIMA**		**Prophet**	
Horizonte	**sMAPE**	**R^2**	**sMAPE**	**R^2**	**sMAPE**	**R^2**	**sMAPE**	**R^2**
1	0.235%	0.995	0.143%	0.998	**0.098%**	**0.999**	3.860%	-0.219
2	0.457%	0.981	0.297%	0.991	**0.231%**	**0.994**	4.006%	-0.331
3	0.672%	0.958	0.463%	0.977	**0.374%**	**0.984**	4.147%	-0.447
5	1.074%	0.890	0.823%	0.927	**0.731%**	**0.940**	4.445%	-0.694
7	1.466%	0.796	**1.209%**	**0.841**	1.228%	0.833	4.730%	-0.962
15	2.766%	0.251	**2.547%**	**0.252**	3.300%	-0.308	5.737%	-2.281
30	4.513%	-1.661	**4.219%**	**-1.615**	6.748%	-5.835	6.801%	-5.496

4.2.2. Modelos com redes neuronais

Para os modeos de redes neuronais com optimização Bayesiana de hiperparâmetros, os resultados foram:

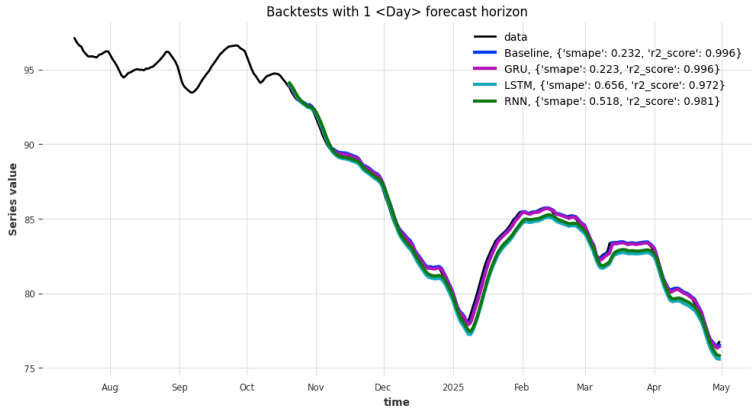


Figura *6* – *Gráfico de resultados de validação deslizante dos modelos de redes neuronais para a série anúncios de emprego no Indeed para o horizonte de um dia*

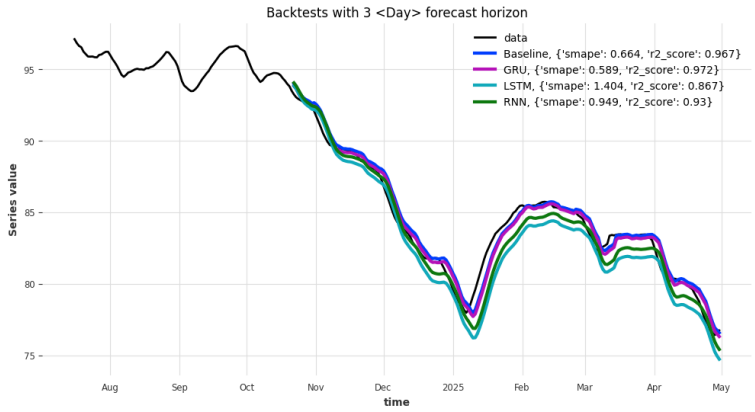


Figura 7 – Gráfico de resultados de validação deslizante dos modelos de redes neuronais para a série anúncios de emprego no Indeed para o horizonte de três dias

Tabela 3 – Resultados de validação deslizante da série anúncios de emprego no Indeed para os modelos de redes neuronais

	Baseline		**RNN**		**LSTM**		**GRU**	
Horizonte	**sMAPE**	**R^2**	**sMAPE**	**R^2**	**sMAPE**	**R^2**	**sMAPE**	**R^2**
1	0.232%	0.996	0.518%	0.981	0.656%	0.972	**0.223%**	**0.996**
2	0.451%	0.985	0.644%	0.968	1.021%	0.931	**0.409%**	**0.987**
3	0.664%	0.967	0.949%	0.930	1.404%	0.867	**0.589%**	**0.972**
5	1.071%	0.912	1.388%	0.840	2.193%	0.664	**0.940%**	**0.926**
7	1.473%	0.832	1.819%	0.706	3.022%	0.347	**1.267%**	**0.861**
15	2.831%	0.326	3.685%	-0.395	6.807%	-2.650	**2.348%**	**0.459**
30	4.740%	-1.438	7.817%	-6.166	15.678%	-20.481	**3.945%**	**-0.970**

Tabela 4 – Comparação final entre os paradigmas de modelação para a série anúnicos de emprego no Indeed

	Modelos Clássicos		**Redes Neuronais**	
Horizonte	**sMAPE**	**R^2**	**sMAPE**	**R^2**
1	**0.098%**	**0.999**	0.223%	0.996
2	**0.231%**	**0.994**	0.409%	0.987
3	**0.374%**	**0.984**	0.589%	0.972
5	**0.731%**	**0.940**	0.940%	0.926
7	**1.209%**	**0.841**	1.267%	0.861
15	2.547%	0.252	**2.348%**	**0.459**

4.3. Rendimentos das obrigações a 10 anos do Reino Unido

4.3.1. Modelos clássicos

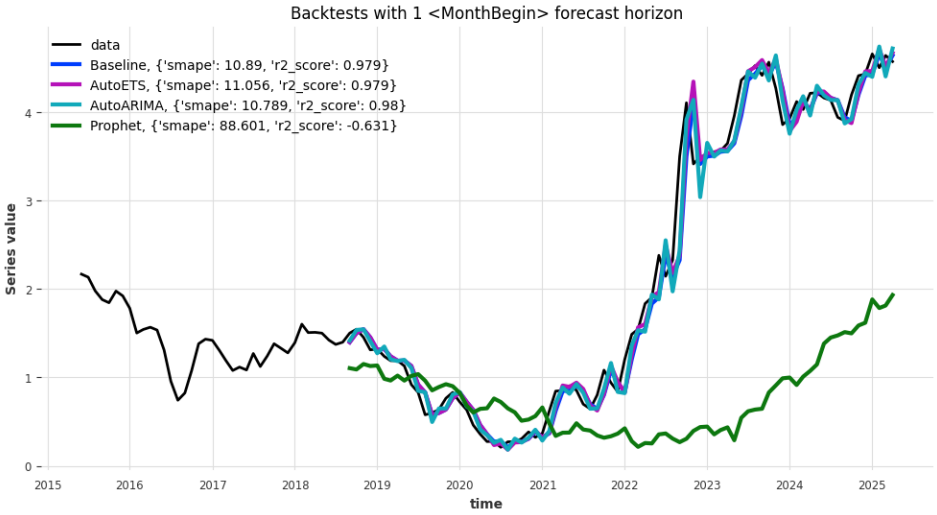


Figura 8 - Gráfico de resultados de validação deslizante dos modelos clássicos para a série rendimentos de obrigações para o horizonte de um dia

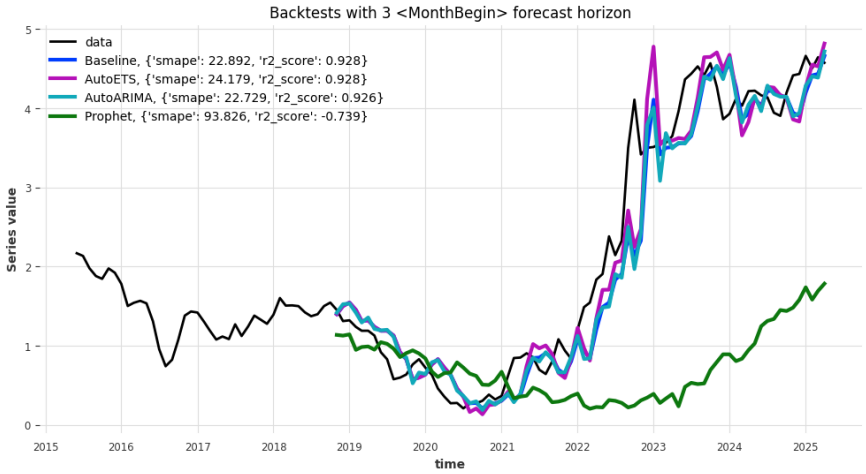


Figura 9 - Gráfico de resultados de validação deslizante dos modelos clássicos para a série rendimentos de obrigações para o horizonte de três dias

Tabela 5 - Resultados de validação deslizante da série rendimentos das obrigações para os modelos clássicos

	Baseline		**AutoETS**		**AutoARIMA**		**Prophet**	
Horizonte	**sMAPE**	**R^2**	**sMAPE**	**R^2**	**sMAPE**	**R^2**	**sMAPE**	**R^2**
1	10.89%	0.979	11.06%	0.979	**10.79%**	**0.980**	88.60%	-0.631
2	**17.39%**	**0.950**	17.91%	0.948	17.66%	0.948	91.08%	-0.683
3	***22.89%***	***0.928***	***24.18%***	***0.928***	***22.73%***	***0.926***	93.83%	-0.739
5	32.50%	0.866	**34.41%**	**0.870**	32.17%	0.866	99.82%	-0.870
7	41.16%	0.798	***42.68%***	***0.816***	***40.86%***	***0.795***	106.36%	-1.012
15	70.12%	0.310	***70.28%***	***0.373***	***70.04%***	***0.310***	132.16%	-1.753
30	102.08%	-2.016	**98.54%**	**-1.826**	101.69%	-2.006	161.57%	-4.788

4.3.2. Modelos com redes neuronais

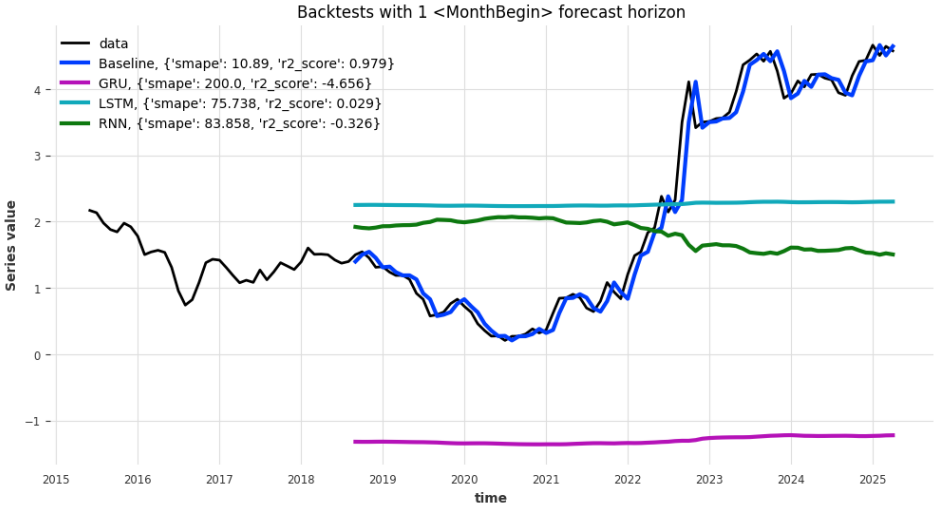


Figura 10 - Gráfico de resultados de validação deslizante dos modelos de redes neuronais para a série rendimentos de obrigações para o horizonte de um dia

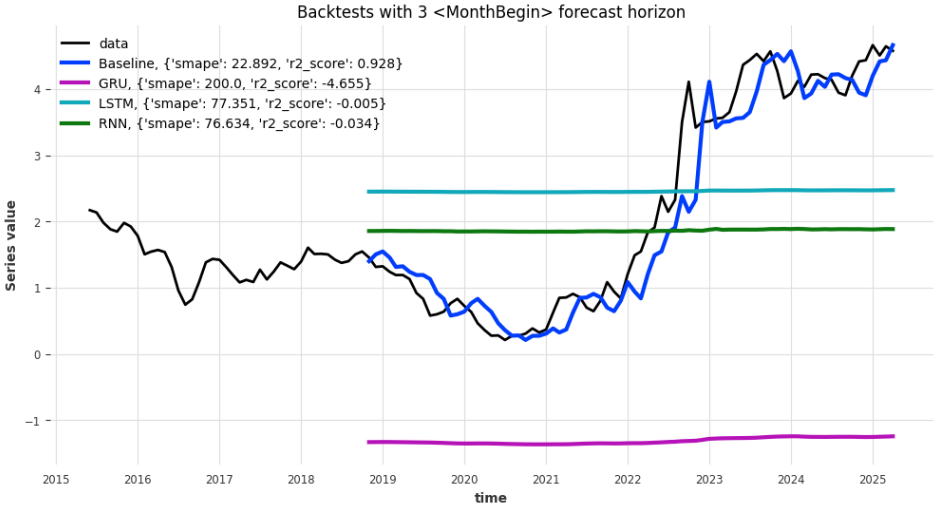


Figura *11* - *Gráfico de resultados de validação deslizante dos modelos de redes neuronais para a série rendimentos de obrigações para o horizonte de três dias*

Tabela 6 - Resultados de validação deslizante da série rendimentos das obrigações para os modelos de redes neuronais

	Baseline		**RNN**		**LSTM**		**GRU**	
Horizonte	**sMAPE**	**R^2**	**sMAPE**	**R^2**	**sMAPE**	**R^2**	**sMAPE**	**R^2**
1	**10.89%**	**0.979**	83.86%	-0.326	75.74%	0.029	200%	-4.656
2	**17.39%**	**0.950**	75.33%	-0.015	76.59%	0.012	200%	-4.588
3	**22.89%**	**0.928**	76.63%	-0.034	77.35%	-0.005	200%	-4.655
5	**32.50%**	**0.866**	78.66%	-0.064	78.18%	-0.026	200%	-4.807
7	**41.16%**	**0.798**	79.55%	-0.064	78.56%	-0.031	200%	-4.885
15	**70.12%**	**0.310**	80.32%	-0.123	75.98%	-0.008	200%	-5.284
30	102.08%	-2.016	66.57%	-0.667	**55.78%**	**-0.092**	200%	-9.473

Tabela 7 – Comparação final entre os paradigmas para a série rendimentos das obrigações

	Modelos Clássicos		**Redes Neuronais**	
Horizonte	**sMAPE**	**R^2**	**sMAPE**	**R^2**
1	**10.79%**	**0.980**	75.74%	0.029
2	**17.66%**	**0.948**	76.59%	0.012
3	**22.73%**	**0.926**	77.35%	-0.005
5	**34.41%**	**0.870**	78.18%	-0.026
7	**42.68%**	**0.816**	78.56%	-0.031
15	**70.28%**	**0.373**	75.98%	-0.008
30	98.54%	-1.826	**55.78%**	**-0.092**

4.4. Análise dos resultados das redes convolucionais

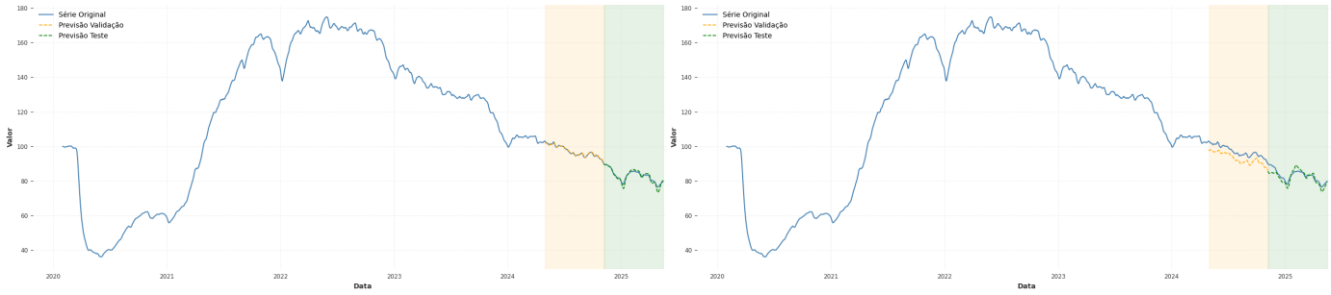
4.4.1. Tensorflow

Tabela 8 - Tensorflow (Fixed Window - CNN)

Time Series	**MAPE**	**MAE**	**SMAPE**	**Train Time (s)**	**Frequência**	**Linhas**
Job Postings UK		4.1208	5.17%	29	Diário	1932
UK Interest Rates & Bond Yields		1.5368	78.65%	3	Mensal	784
UK Consumer Price Index (CPI)		7.0180	6.34%	12	Mensal	843

Tabela 9 - Tensorflow (Fixed Window - Híbrido)

Time Series	**MAPE**	**MAE**	**SMAPE**	**Train Time (s)**	**Frequência**	**Linhas**
Job Postings UK		0.6894	0.85%	134.45	Diário	1932
UK Interest Rates & Bond Yields		1.5275	78.74%	9	Mensal	784
UK Consumer Price Index (CPI)		15.3888	13.58%	69	Mensal	843



Esq: Hibrido || Direito: CNN

Tabela 10 - Sliding Window Cross Validation 10 Folds (Modelo Híbrido - Tensorflow)

Janela	Data Início	Data Fim	Tempo de Treino (s)	MAE	SMAPE
1	01/02/2020	11/08/2020	10.141400	2.547551	5.817232
2	12/08/2020	20/02/2021	11.621212	5.598737	9.456594
3	21/02/2021	01/09/2021	12.884648	45.448030	37.769417
4	02/09/2021	13/03/2022	12.060918	13.955253	8.836456
5	14/03/2022	22/09/2022	11.929813	1.397782	0.828085
6	23/09/2022	03/04/2023	7.120922	1.378818	0.989454
7	04/04/2023	13/10/2023	13.088985	0.817273	0.635888
8	14/10/2023	23/04/2024	11.915910	1.629759	1.568282
9	24/04/2024	02/11/2024	7.655618	1.106697	1.175169
10	03/11/2024	16/05/2025	6.673724	1.158504	1.475080
Tempo de Treino Total: 105.09 segundos					



Figura 12 - Sliding Window Cross-Validation (10 Folds): Job Postings UK – Tensorflow

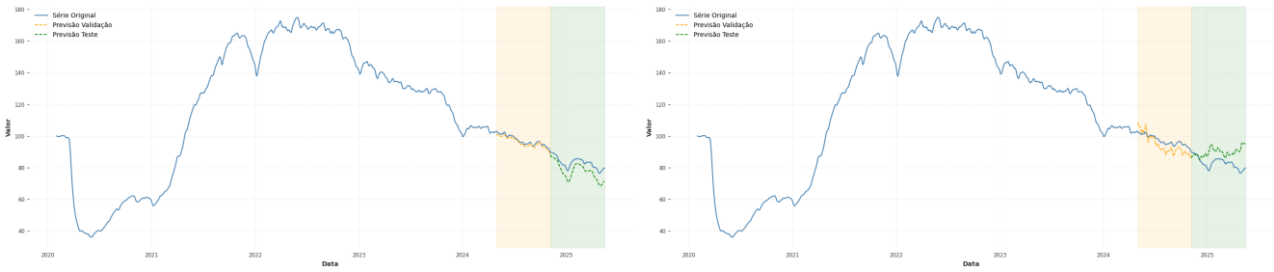
4.4.2. Pytorch

Tabela 11 - Pytorch (Fixed Window - CNN)

Time Series	MAPE	MAE	SMAPE	Train Time	Frequência	Linhas
Job Postings UK	3.39%	7.0145	8.15%	1.43s	Diário	1932
UK Interest Rates & Bond Yields	127.20%	1.2476	88.94%	2.33s	Mensal	784
UK Consumer Price Index (CPI)	12.53%	14.6841	13.39%	0.93s	Mensal	843

Tabela 12 - Pytorch (Fixed Window - Modelo Hibrido)

Time Series	MAPE	MAE	SMAPE	Train Time	Frequência	Linhas
Job Postings UK	4.19%	3.4508	4.29%	3.47s	Diário	1932
UK Interest Rates & Bond Yields	67.47%	0.8503	48.04%	2.42s	Mensal	784
UK Consumer Price Index (CPI)	17.26%	20.9713	19.12%	0.68s	Mensal	843



Esq: Hibrido || Direito: CNN

Tabela 13 - Sliding Window Cross Validation 10 Folds (Modelo Híbrido - Pytorch)

Janela	Data Início	Data Fim	Tempo de Treino (s)	MAE	SMAPE
1	01/02/2020	11/08/2020	0.225169	4.577332	10.417405
2	12/08/2020	20/02/2021	0.897003	2.570705	4.264314
3	21/02/2021	01/09/2021	1.258106	27.930956	22.203427
4	02/09/2021	13/03/2022	1.647963	7.140640	4.491455
5	14/03/2022	22/09/2022	2.405533	1.634013	0.968092
6	23/09/2022	03/04/2023	2.703252	5.432245	3.795208
7	04/04/2023	13/10/2023	2.972180	1.094322	0.849278
8	14/10/2023	23/04/2024	3.287216	2.134237	2.034089
9	24/04/2024	02/11/2024	3.605089	1.942762	2.043391
10	03/11/2024	16/05/2025	3.892826	1.323468	1.650856
Tempo de Treino Total: 22.89 segundos					



Figura *13* **-** Sliding Window Cross-Validation (10 Folds): Job Postings UK - Pytorch

4.4.3. Darts – TCN

Tabela *1***14 -** Resultados Fixed Window TCN (DARTS)

Time Series	MAPE	MAE	SMAPE	Train Time	Frequência	Linhas
Job Postings UK	5.2021%	4.264	5.363%	9.15s	Diário	1932
UK Interest Rates & Bond Yields	235.312%	1.418	68.753%	2.65s	Mensal	784
UK Consumer Price Index (CPI)	24.137%	29.583	28.491%	4.33s	Mensal	843

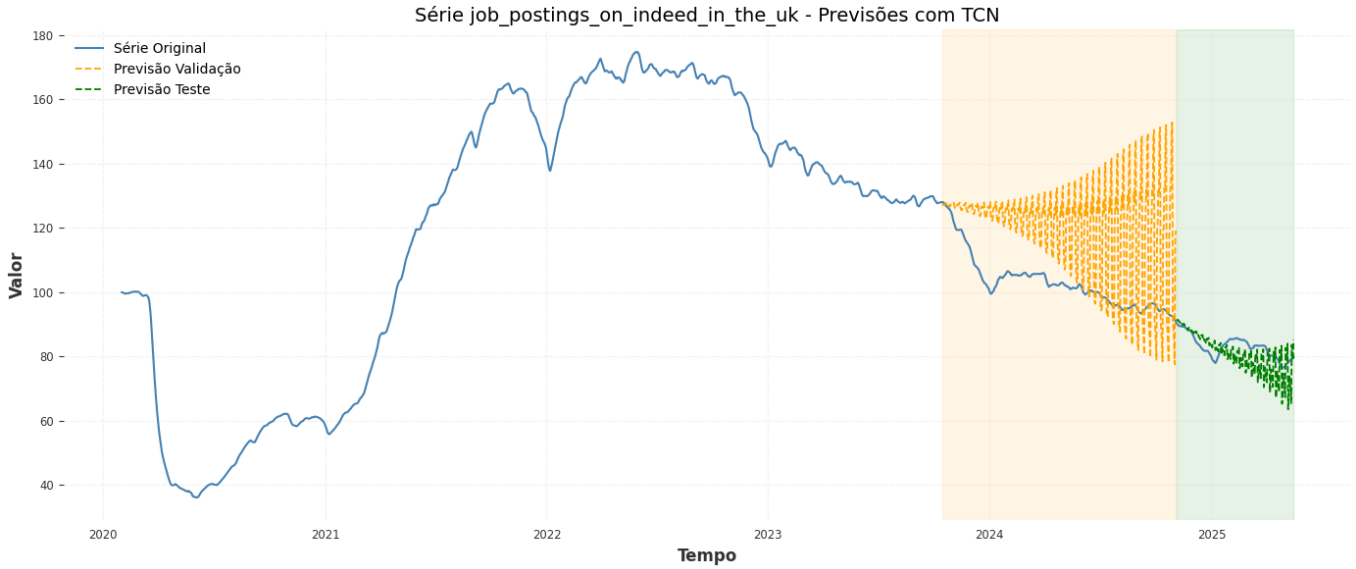


Figura 14 - TCN previsão para Job Posting

Tabela 15 - Sliding Window Cross Validation 10 Folds (Modelo TCN – DARTS)

Janela	Data Início	Data Fim	Tempo de Treino (s)	MAE	SMAPE (%)
1	01/02/2020	11/08/2020	0.664956	30.000134	18.901714
2	12/08/2020	20/02/2021	0.471751	3.489202	3.990755
3	21/02/2021	01/09/2021	1.527014	34.152294	6.576177
4	02/09/2021	13/03/2022	0.386911	6.159991	4.752601
5	14/03/2022	22/09/2022	0.402307	1.739342	1.396165
6	23/09/2022	03/04/2023	0.289308	10.218290	6.967124
7	04/04/2023	13/10/2023	0.300944	2.787582	1.105467
8	14/10/2023	23/04/2024	0.433716	8.783948	1.279365
9	24/04/2024	02/11/2024	0.312377	2.795967	4.481625
10	03/11/2024	14/05/2025	0.305901	2.495511	6.645909
Tempo de Treino Total: 5.14 segundos					



Figura 15 - Sliding Window Cross-Validation (10 Folds): Job Postings UK - Modelo TCN – DARTS

4.5. Relação de causalidade com a incerteza Política no Reino Unido

Tabela 216 - Correlação de Pearson com a Incerteza Politica

Serie	Correlação Pearson	Frequência
Empregos_Indeed_UK	-0.4533	Diária
Taxas_Juro_10Y_UK	-0.2994	Mensal
Precos_Casas_UK	0.0412	Trimestral
PIB_UK	0.0067	Trimestral
Indice_Precos_Consumo_UK	0.0682	Mensal

Tabela 317 - Correlação lag de Pearson com a incerteza Politica

Serie	Linhas	Lag	Correlação Pearson	Frequência
Empregos_Indeed_UK	1904	12	-0.466269	Diária
Taxas_Juro_10Y_UK	290	2	-0.336575	Mensal
Precos_Casas_UK	85	-11	0.191017	Trimestral
PIB_UK	84	12	0.236518	Trimestral
Indice_Precos_Consumo_UK	279	12	0.0877127	Mensal

Tabela 418 - Séries com Relação de Causalidade de Granger Significativa ($p < 0.05$)

Serie	Lag	P_Valor
Empregos_Indeed_UK	1	8.93e-14
Taxas_Juro_10Y_UK	1	2.10e-02
Taxas_Juro_10Y_UK	3	4.85e-02

5. DISCUSSÃO

As várias metodologias empregadas para a análise e modelação das séries temporais diferiram na qualidade dos resultados obtidos nos diferentes contextos. Foram observados melhores desempenhos com técnicas de maior simplicidade como o ETS, mesmo para séries de complexidade média como os anúncios de emprego, para previsões a curto prazo. Contrariamente, as vantagens da utilização de redes neuronais revelaram-se principalmente nas previsões a longo prazo. O modelo *baseline* de comparação também obtém bons resultados nas previsões mais curtas, contudo sendo ultrapassado pelos modelos clássicos.

5.1. Modelos clássicos vs redes neuronais

Os modelos clássicos mostraram suficiente adaptabilidade às séries temporais estudadas até horizontes de 7 períodos temporais segundo as métricas analisadas, aliado à baixa complexidade de treino e maior interpretabilidade.

Destacam-se os modelos de AutoETS devido ao desempenho próximo do melhor modelo ARIMA, com tempos de treino cerca de 6.8x inferiores. Ao mesmo tempo, a implementação do Facebook Prophet não foi de encontro ao necessário para modelar suficientemente as séries temporais, demonstrando consistententemente os piores resultados dentro dos modelos clássicos.

Na série temporal dos anúncios de emprego do Indeed, as redes neuronais demonstraram resultados promissores, com a arquitetura GRU a prevalecer. Já na série das obrigações anuais, as redes neuronais não captaram informação suficiente para a previsão da série, demonstrando métricas de performance muito fracas. Neste contexto, não é justificado o uso de redes neuronais, visto que requerem um maior tempo de optimização de hiperparâmetros e podem não encontrar as dependências temporais de séries de menor dimensão/com poucas observações.

5.1.1. Comparação entre diferentes redes neuronais

Considerando o desempenho geralmente superior dos modelos clássicos para previsões a curto prazo, as arquiteturas de redes neuronais obtiveram melhores resultados para previsões a longos prazos, tornando este o principal foco de análise destas implementações. Os resultados para horizontes de previsão de 15 e 30 dias ficaram aquém, em geral, para ambos os paradigmas. Apesar disto, os modelos de redes neuronais conseguiram alcançar métricas comparativamente melhores.

5.2. Modelação com redes neuronais avançadas

Inicialmente, importa referir que o TensorFlow apresentou algumas limitações técnicas, nomeadamente a ausência de suporte atualizado para CUDA, ao contrário do PyTorch, que dispõe dessa funcionalidade. Esta diferença técnica reflete-se também no desempenho, sendo o PyTorch consideravelmente mais rápido na execução dos modelos. Em termos de resultados, contudo, ambas as frameworks produziram desempenhos muito semelhantes, sem diferenças significativas.

Quanto aos modelos testados, verificou-se que o modelo híbrido demonstrou, na maioria dos casos, superioridade face às redes convolucionais (CNN) puras, embora existam algumas exceções pontuais. A análise de validação cruzada indicou, no entanto, que o modelo híbrido tem dificuldades em séries temporais, com oscilações muito elevadas, onde o seu desempenho é inferior. As redes temporais convolucionais (TCNs) apresentaram resultados geralmente inferiores aos do modelo híbrido.

De forma geral, os modelos obtiveram desempenhos piores em séries temporais com menor quantidade de dados, nomeadamente aquelas com frequências mais baixas (anuais, trimestrais), e melhoraram significativamente em séries com frequências mais elevadas, como as series com informações diárias.

5.3. Causalidade entre séries temporais

Foi necessário ajustar a frequência da incerteza política através da média para alinhar com as outras séries, o que poderá ter causado alguma perda de informação. A correlação de Pearson mais relevante foi com os anúncios de emprego no Indeed, apresentando um valor negativo de -0,45, e com as taxas de juro de longo prazo, com -0,30. Na correlação cruzada, destacou-se um lag de 12 dias para os anúncios de emprego, com correlação de -0,47, e um lag de 2 meses para as taxas de juro, com -0,34. O teste de causalidade de Granger revelou causalidade estatisticamente significativa ($p < 0,05$) entre a incerteza política e os anúncios de emprego (lag 1, $p \approx 9\times10^{-14}$) e as taxas de juro (lags 1 e 3, $p \approx 0,02$ e 0,048). Estes resultados indicam que a incerteza política influência estes indicadores económicos com atrasos curtos.

5.4. Limitações e trabalho futuro

No decorrer do trabalho foram encontrados vários obstáculos na modelação das séries temporais estudadas. As séries de maior número de observações não foram passíveis de serem estudadas em profundidade, pois implicariam um custo computacional exponencialmente mais elevado. Desta forma, a generalização dos resultados encontrados carece de mais testes com novos dados e com recurso a sistemas computacionais de performance mais elevada, ou o desenvolvimento de algoritmos de ainda maior eficácia.

6. CONCLUSÕES

Com os contínuos avanços das tecnologias de modelação de dados em séries temporais, este estudo procurou realizar uma análise comparativa de múltiplas técnicas. Apesar do potencial das redes neuronais e modelos híbridos, os modelos clássicos como o ARIMA e ETS continuam a alcançar precisão preditiva exemplar, com menor custo computacional, especialmente para horizontes de previsão curtos. Por outro lado, os modelos de *Deep Learning* demonstram maior capacidade de captação de padrões complexos e para horizontes temporais mais elevados, acompanhados com um acréscimo do custo computacional.

Pela análise da causalidade, revelou a influência estatisticamente significativa da incerteza política sobre outras varíaveis como os anúncios de emprego e os rendimentos das obrigações, reforçando a inclusão de fatores exógenos na modelação. Em termos metodológicos, o uso de ferramentas modernas como *Darts* e *Optuna* permitiu otimizar e comparar os modelos eficientemente.

O trabalho realizado neste estudo promove o uso de algoritmos de modelação de séries temporais em contextos socioeconómicos voláteis ao combinar rigor estatístico, diversidade metodológica e aplicabilidade prática, formando uma base sólida para futuras aplicações.

REFERÊNCIAS BIBLIOGRÁFICAS

Bai, S., Kolter, J. Z., & Koltun, V. (2018). *An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling* (Versão 2). arXiv. https://doi.org/10.48550/ARXIV.1803.01271

Baker, S. R., Bloom, N., & Davis, S. J. (2016). Measuring Economic Policy Uncertainty*. *The Quarterly Journal of Economics*, *131*(4), 1593–1636. https://doi.org/10.1093/qje/qjw024

Chen, C., Twycross, J., & Garibaldi, J. M. (2017). A new accuracy measure based on bounded relative error for time series forecasting. *PLOS ONE*, *12*(3), e0174202. https://doi.org/10.1371/journal.pone.0174202

Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). *Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling* (Versão 1). arXiv. https://doi.org/10.48550/ARXIV.1412.3555

Gopali, S., Abri, F., Siami-Namini, S., & Namin, A. S. (2021). A Comparison of TCN and LSTM Models in Detecting Anomalies in Time Series Data. *2021 IEEE International Conference on Big Data (Big Data)*, 2415–2420. https://doi.org/10.1109/BigData52589.2021.9671488

Granger, C. W. J. (1969). Investigating Causal Relations by Econometric Models and Cross-spectral Methods. *Econometrica*, *37*(3), 424. https://doi.org/10.2307/1912791

He, Y., & Zhao, J. (2019). Temporal Convolutional Networks for Anomaly Detection in Time Series. *Journal of Physics: Conference Series*, *1213*(4), 042050. https://doi.org/10.1088/1742-6596/1213/4/042050

Herzen, J., Lässig, F., Piazzetta, S. G., Neuer, T., Tafti, L., Raille, G., Van Pottelbergh, T., Pasieka, M., Skrodzki, A., Huguenin, N., Dumonal, M., Kościsz, J., Bader, D., Gusset, F., Benheddi, M., Williamson, C., Kosinski, M., Petrik, M., & Grosch, G. (2021). *Darts: User-Friendly Modern Machine Learning for Time Series*. https://doi.org/10.48550/ARXIV.2110.03224

Holt, C. C. (2004). Forecasting seasonals and trends by exponentially weighted moving averages. *International Journal of Forecasting*, *20*(1), 5–10. https://doi.org/10.1016/j.ijforecast.2003.09.015

Lea, C., Flynn, M. D., Vidal, R., Reiter, A., & Hager, G. D. (2017). Temporal Convolutional Networks for Action Segmentation and Detection. *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 1003–1012. https://doi.org/10.1109/CVPR.2017.113

Lecun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, *86*(11), 2278–2324. https://doi.org/10.1109/5.726791

Mehtab, S., Sen, J., & Dasgupta, S. (2020). *Robust Analysis of Stock Price Time Series Using CNN and LSTM-Based Deep Learning Models*. https://doi.org/10.48550/ARXIV.2011.08011

Novac, O.-C., Chirodea, M. C., Novac, C. M., Bizon, N., Oproescu, M., Stan, O. P., & Gordan, C. E. (2022). Analysis of the Application Efficiency of TensorFlow and PyTorch in Convolutional Neural Network. *Sensors*, *22*(22), 8872. https://doi.org/10.3390/s22228872

Ramesh, A. C., & Usman, M. (sem data). *Empirical Study of Neural Network and other Machine Learning Models in Time Series Forecasting using Sales Data*.

Runge, J. (2013). *On the graph-theoretical interpretation of Pearson correlations in a multivariate process and a novel partial correlation measure* (Versão 1). arXiv. https://doi.org/10.48550/ARXIV.1310.5169

Shang, Z., Zhang, Y., Zhang, X., Zhao, Y., Cao, Z., & Wang, X. (2021). Time Series Anomaly Detection for KPIs Based on Correlation Analysis and HMM. *Applied Sciences*, *11*(23), 11353. https://doi.org/10.3390/app112311353

Taylor, S. J., & Letham, B. (2018). Forecasting at Scale. *The American Statistician*, *72*(1), 37–45. https://doi.org/10.1080/00031305.2017.1380080

Tian, Y., Ma, S., Rui, R., Yu, Z., & Tian, M. (2021). The Analysis of Impact of Brexit on the Post-Brexit EU Using Intervented Multivariate Time Series. *Acta Mathematicae Applicatae Sinica, English Series*, *37*(3), 441–458. https://doi.org/10.1007/s10255-021-1022-z

Wang, Z., Yan, W., & Oates, T. (2016). *Time Series Classification from Scratch with Deep Neural Networks: A Strong Baseline* (Versão 4). arXiv. https://doi.org/10.48550/ARXIV.1611.06455

Wen, T., & Keyes, R. (2019). *Time Series Anomaly Detection Using Convolutional Neural Networks and Transfer Learning* (Versão 1). arXiv. https://doi.org/10.48550/ARXIV.1905.13628

Willmott, C., & Matsuura, K. (2005). Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. *Climate Research*, *30*, 79–82. https://doi.org/10.3354/cr030079

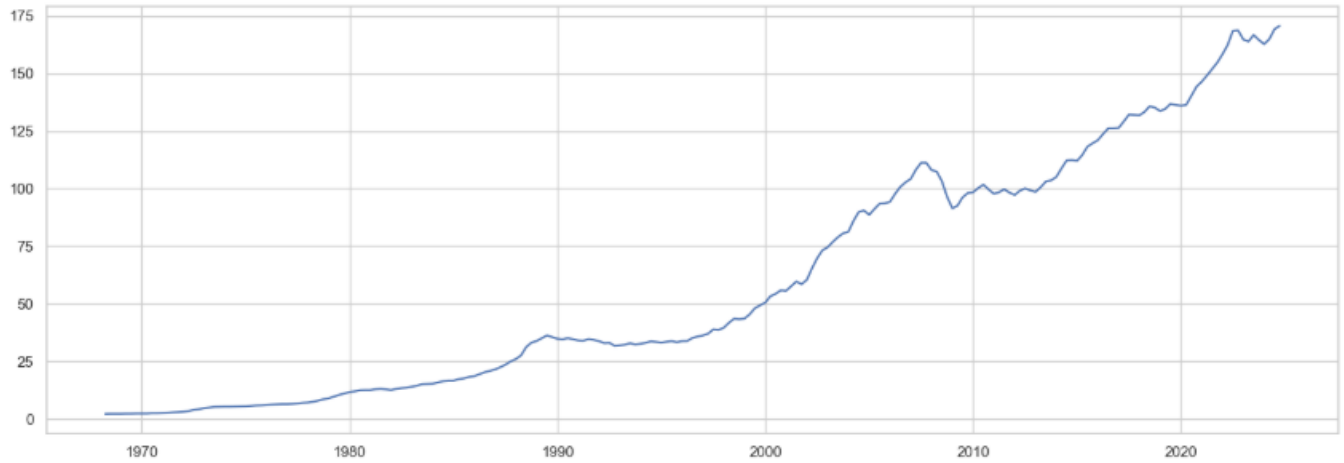
Zebin, T., Scully, P. J., Peek, N., Casson, A. J., & Ozanyan, K. B. (2019). Design and Implementation of a Convolutional Neural Network on an Edge Computing Smartphone for Human Activity Recognition. *IEEE Access*, *7*, 133509–133520. https://doi.org/10.1109/ACCESS.2019.2941836

Zhang, G. P. (2003). Time series forecasting using a hybrid ARIMA and neural network model. *Neurocomputing*, *50*, 159–175. https://doi.org/10.1016/S0925-2312(01)00702-0

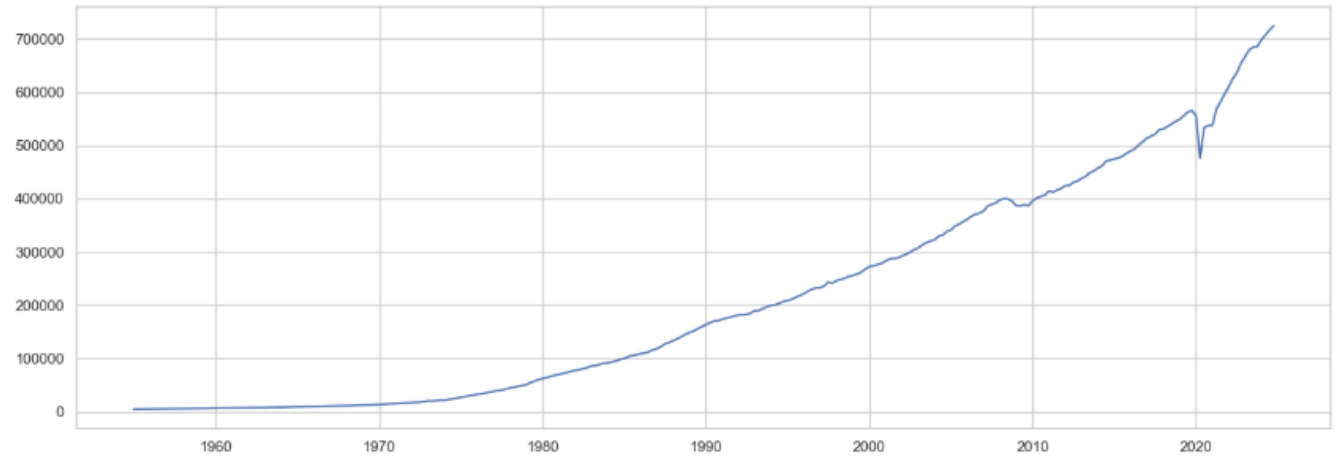
ANEXOS

Anexo A: Séries Temporais

Anexo A1 - Índice de Preços ao Consumidor para o Reino Unido



Anexo A2 - Série Temporal do Preços da Propriedade Residencial do Reino Unido:



Anexo A3 – Série Temporal do Produto Interno Bruto do Reino Unido:

